

Plataforma conversacional transaccional con IA

Propuesta de arquitectura

Un cliente llama por teléfono o escribe por chat. Un agente de IA lo atiende y **ejecuta acciones reales de negocio**. Este documento presenta la arquitectura de una plataforma que lo hace **para múltiples clientes sobre un único despliegue** — y que está construida y en operación. El sistema en vivo no es el entregable: es la verificación — ninguna decisión se sostiene por estar implementada, sino por su justificación.

PLATAFORMA EN VIVO

<https://lk.bernardocastro.dev>

▶ Ver demo /demo.html

y por teléfono: +1 417 674 3169 — atiende la clínica

EL AGENTE, HOY

Diez encargos reales por voz o chat

Clínica — identifica al paciente, reserva, mueve y cancela citas, confirma asistencia, actualiza el teléfono, envía SMS. Comercio — estado del pedido, cancelación, tickets. Toda acción definitiva, solo tras el «sí» explícito del cliente.

LA OPERACIÓN

Cada llamada, gobernada y auditada

Llamadas en vivo con supervisión — escuchar, susurrar, tomar la línea. Cada sesión con grabación, transcripción, coste y nota de calidad automática. El tablero de citas, pedidos y tickets, y las evaluaciones ejecutables desde la consola.

CÓMO SE CONSTRUYÓ

Veinte hitos incrementales, ninguno a ciegas

Desarrollo incremental con **agentes de Claude Code en paralelo**, cada tarea en su rama aislada — y **yo en el bucle**: leyendo el código, probándolo y aprobando personalmente el cierre de cada hito, con su reporte de aprendizaje. Stack elegido con criterio: **LiveKit autoalojado, no Vapi ni Pipecat** — un agente transaccional no se configura en un panel: exige poseer el bucle (el porqué completo, lámina 15). El board es público:
<https://taskops.bernardocastro.dev/convo>

Cuatro piezas: canales, conversación, control de negocio y sistemas del cliente

La plataforma separa la **conversación** (tiempo real, donde opera la IA) del **control de negocio** (donde se valida, se autoriza y se registra). Esa frontera es la garantía central del diseño: el modelo de IA genera lenguaje — las operaciones las ejecuta y audita el backend.



LA PATA TELEFÓNICA, PROPIA número público → operador (troncal SIP) → puente SIP y servidor de medios **propios, autoalojados** → el número marcado decide qué negocio atiende (una fila de configuración, no un despliegue) → y la transferencia a un humano es una operación SIP estándar. La señalización solo se acepta desde las IP publicadas del operador.

En operación: dos negocios sobre un único despliegue — telefonía, voz web y chat — verificable en <https://lk.bernardocastro.dev>

La calidad no se promete: se mide en cada cambio, cada noche y cada llamada

Un agente de IA se degrada en silencio: un cambio de prompt, de proveedor o de modelo rompe una regla sin que nadie lo note. La respuesta: **cuatro niveles de evaluación automática** — del laboratorio a la llamada real.

- 01

En cada cambio de código

Decenas de conversaciones de prueba juzgan al agente antes de desplegar. Las reglas de negocio no son opiniones: «nunca reservar sin un sí explícito» se verifica con código y da 1 o 0.
- 02

Cada noche, con voz real

Un cliente sintético llama de verdad a la plataforma desplegada — habla, interrumpe, mezcla idiomas — con presupuesto acotado. Un resultado en rojo detiene la noche en rojo, nunca en un falso verde.
- 03

Cualquier llamada real, bajo demanda

El historial de una llamada almacenada se reevalúa con las mismas métricas — el replay no necesita el audio, le basta la evidencia.
- 04

Cada llamada, automáticamente al terminar

Cuatro verificaciones de código (consentimiento, trato, privacidad, errores) más un juez de IA. Coste medido: entre 0,0014 y 0,0018 € por llamada; la nota aparece en la consola junto a la grabación.

EL EXAMEN ES UN DATASET VERSIONADO

Goldens por proyecto, junto al código del negocio

Cada proyecto lleva su **dataset de goldens** — casos reales convertidos en escenarios con resultado esperado — versionado en git, creciendo con cada hito y ejecutado por **DeepEval** en cada integración: la regla que rompió una llamada ayer es un caso del examen hoy. Y el mismo dataset examina a **Claude y a GPT lado a lado** — las políticas duras puntúan 100% en ambos; cambiar de proveedor es una decisión con datos, no una migración a ciegas.

QUÉ SE MIDE

Consentimiento — nunca operar sin un «sí» explícito (verdicto 1/0)

Veracidad — todo dato tiene fuente; nada inventado

Trato — usted y tono profesional, siempre

Privacidad — ninguna fuga de datos entre clientes


Herramientas — la correcta, con los argumentos que dijo el cliente

Latencia y coste — por turno, en segundos y céntimos

Las evaluaciones se ven y se ejecutan desde la consola (sección Evals), con la comparación entre corridas – <https://lk.bernardocastro.dev>

Una llamada real, paso a paso: leer es libre, operar exige un sí

Cada llamada vive en un proceso aislado que muere con ella. El historial se escribe **mientras la llamada ocurre**, paso a paso — si el proceso cae a mitad, la evidencia ya está guardada.




La secuencia completa, con sus números de orden y tiempos, es consultable por llamada en la consola (sección Sessions) – <https://lk.bernardocastro.dev>

Seis dominios con fronteras estrictas; dentro de la conversación, un pipeline medido

Cada dominio posee una cosa y se niega al resto. La frontera más importante es la primera: **la conversación no conoce negocios y el control de negocio no conoce audio** — se hablan por un contrato, no por dependencias compartidas.

Conversación Tiempo real: audio, turnos, el modelo de IA. Un proceso aislado por llamada.	Control de negocio Contratos de tools, autorización en dos fases, ejecución contra los sistemas del cliente.	Evidencia Historial numerado, grabación, coste y nota de calidad. Solo se añade; nunca se edita.
Tenancy Verticales (el código del rubro: clínica, retail) y negocios (su configuración: voz, número, datos). Un negocio roto queda fuera de ruta — la flota sigue.	Evaluación Los cuatro niveles de la lámina 3. Juzga con las mismas métricas en todos, sin tocar producción.	Operación La consola: supervisar en vivo, configurar sin desplegar, auditar cada llamada.



La frontera conversación / negocio está garantizada por prueba automática: el núcleo no puede importar código de ningún cliente, y el intento rompe la build.

Lo que queda de una llamada: la sesión completa, en la consola

CANAL	INICIO	DURACIÓN	TURNOS	EVENTOS	COSTE TOTAL	NOTA AUTOMÁTICA
teléfono	08:24 PM	2m 23s	19	109	0,0162 €	0,98

Etapas recorridas: Identificación → Reserva nueva → Despedida · resultado: el cliente colgó al terminar

▶

0:00

2:23

Grabación estéreo — el cliente en un canal, el agente en el otro, sobre una misma línea de tiempo. El archivo nunca sale del servidor salvo por esta ruta autenticada: no está en un directorio público ni en el repositorio.

Primera palabra del modelo	Extremo a extremo	Fin de turno detectado	Transcripción	Primera sílaba de voz
0,83 s	2,19 s	0,35 s	0,29 s	0,12 s
máx 1,83 s · 8 turnos	máx 2,52 s · 6 turnos	máx 2,50 s · 9 turnos	máx 0,49 s · 9 turnos	máx 0,28 s · 10 turnos

Esta llamada, completa y en vivo: https://lk.bernardocastro.dev/t/clinica-norte/reagendamiento/sessions/AJ_yiCGykqgxwMu

La misma llamada, por dentro: cómo se ganó su 0,98 — y el historial que lo prueba

✓	Consentimiento VERIFICADO POR CÓDIGO	toda operación irreversible tuvo su confirmación concedida antes: crear_cita
✓	Trato VERIFICADO POR CÓDIGO	ninguna forma no permitida en 10 turnos del agente — usted, siempre
✓	Privacidad VERIFICADO POR CÓDIGO	ningún dato de otro negocio mencionado en toda la llamada
✓	Errores VERIFICADO POR CÓDIGO	ningún error de proveedor durante la conversación
✓	Calidad · 0,90 JUEZ DE IA	coste del juicio: 0,0018 € — bajo un tope de 0,01 € comprobado antes de llamar

EL JUEZ, EN SU PROPIA EXPLICACIÓN

«La paciente llamó para pedir una cita nueva de fisioterapia. Recepción la agendó para el martes 1 de septiembre a las 09:00 con Eva Durán, la confirmó con la paciente y le informó de que recibiría un SMS. La petición quedó totalmente resuelta.»

EL HISTORIAL, TAL CUAL — 12 DE LOS 109 EVENTOS

1	inicio de sesión	proyecto clínica · canal teléfono · voz Carolina Ruiz
2	etapa	Identificación
4	grabación	comienza a escribirse — sobrevive aunque el proceso muera
8	turno · agente	«Clínica Norte, buenos días, le atiende recepción. ¿En qué puedo ayudarle?» voz en 0,12 s
11	turno · cliente	«Hola.» transcrito en 0,24 s
27	turno · cliente	«Sí, mi nombre completo es Bernardo Castro.»
...	etapa	Reserva nueva — la agenda se consulta antes de ofrecer
...	turno · cliente	«Sí, confirmo.»
...	autorización	vale de un solo uso emitido para crear_cita
...	operación	cita creada: martes 1/9, 09:00, Eva Durán
...	operación	SMS de confirmación enviado con los datos personales enmascarados en el registro
109	nota	0,98 — escrita en el mismo historial, con el número de orden siguiente

Esta llamada corrió sobre gpt-5.4-mini — el modelo es un componente intercambiable, y la auditoría es idéntica con cualquiera. Historial completo: https://lk.bernardocastro.dev/t/clinica-norte/reagendamiento/sessions/AJ_yiCGykqgxwMu

Cada acción de negocio es un contrato declarado, no una función suelta

Un **tool** es la única manera en que la IA toca el mundo real. Antes de existir, cada uno declara su contrato: qué efecto tiene, qué se registra, cuánto puede tardar y cómo se deshace. El sistema gobierna por el **efecto declarado**, nunca por el nombre.

Leer	consultar la agenda, buscar un pedido — libre: no cambia nada
Escribir	enviar un SMS, abrir un ticket — se puede compensar si algo sale mal
Irreversible	crear, mover o cancelar una cita — exige la confirmación explícita del cliente , con un vale de un solo uso

El error tiene dos audiencias

Fallo de negocio — «esa hora acaba de ocuparse» — llega al agente, que lo explica al cliente y ofrece alternativa.

Fallo técnico — una excepción, un timeout — jamás llega a la conversación: se registra, y el agente sigue con lo que sí puede hacer.

crear_citaEFFECTO: IRREVERSIBLE	
CONFIRMACIÓN	solo se ejecuta con un vale emitido tras el «sí» del cliente — el vale sirve para esta operación exacta y caduca en 120 s
PRIVACIDAD	nombre y teléfono se enmascaran en el registro — incluso dentro del texto de un SMS
TIEMPO MÁXIMO	5 s — si el sistema del cliente no responde, el agente lo dice y la llamada continúa
RESUMEN AUDITABLE	la línea que queda en el historial, ya filtrada: «cita ap-...-0900 creada, martes 1/9 09:00»
COMPENSACIÓN	declara qué la deshace (cancelar_cita) — la base de una transacción de varios pasos
IDEMPOTENCIA	repetir la misma orden no duplica la cita

EL CATÁLOGO DE HOY, POR NEGOCIO — EL EFECTO GOBIERNA CADA UNO

Clínica: buscar paciente leer · disponibilidad leer · proponer cita leer · crear cita irreversible · mover cita irreversible · enviar SMS escribir

Tienda: buscar pedido leer · pedir cancelación leer · cancelar pedido irreversible · abrir ticket escribir · estado del ticket leer

El rechazo es código en producción: una orden irreversible sin su vale no se ejecuta – verificado por test, y visible como evento en el historial de cualquier llamada que lo intente.

Un humano siempre puede entrar — y su autoridad viaja firmada

La IA atiende sola, pero la operación nunca pierde el control. Un supervisor dispone de cuatro capacidades sobre cualquier llamada en curso — y cada una es un **permiso firmado que caduca en 15 minutos**, no un botón que cualquiera aprieta.

INVISIBLE PARA EL CLIENTE

Escuchar

Oye y lee la llamada en vivo. No puede hablar ni publicar nada: su permiso físicamente no lo permite.

SOLO EL AGENTE LA RECIBE

Susurrar

Una instrucción escrita — «ofrézcale el jueves» — que el agente obedece en su siguiente frase. El cliente jamás la oye ni la ve.

LA IA CALLA AL INSTANTE

Tomar la línea

Habla el humano; la IA escucha en silencio. Al devolver la línea, el agente retoma sabiendo lo que se dijo en su ausencia.

A UN TELÉFONO HUMANO

Transferir

La llamada sale hacia el número configurado. Si el destino no contesta, el cliente no se pierde: sigue con el agente, que se lo explica.

CÓMO VIAJA LA AUTORIDAD

Capacidad solicitada escuchar, susurrar, tomar o transferir	→	Permiso firmado con los poderes exactos de esa capacidad y caducidad de 15 minutos	→	Una sola puerta la identidad la certifica el servidor de medios — nada escrito en un mensaje puede fingirse supervisor	→	Todo al historial cada intervención queda numerada en el registro de la llamada
Verificado contra el servidor real: un oyente oculto es invisible incluso para el agente — por eso el ingreso lo certifica y registra el servidor, no la sala.						

Operativo en producción: consola → Supervisor — las llamadas en curso, con los cuatro verbos sobre cada una. <https://lk.bernardocastro.dev/supervisor>

El modelo propone, la máquina dispone — y ningún fallo deja el sistema a medias

Una operación de negocio no es una frase afortunada del modelo: es un procedimiento con pasos verificables. Y el estado que lo respalda está escrito **antes** de que cualquier cosa pueda fallar.

- 01

El modelo propone. Quiere crear la cita — pero primero la plataforma lee el resumen al cliente, con una frase que redacta la plataforma, no el modelo: lo que se confirma es exacto.
- 02

El cliente autoriza. Su «sí» emite un vale de un solo uso, atado a esa operación exacta con esos datos exactos. Caduca en 120 segundos.
- 03

La máquina ejecuta. Solo con vale válido. La autorización es un paso de código con firma — nunca una interpretación del tono de la conversación.
- 04

Varios pasos, una transacción. Cada paso declara qué lo deshace; si el tercero falla, se compensan el segundo y el primero. El cliente nunca queda con media operación hecha.

El historial es la única fuente de verdad
Numerado, solo-añadir, escrito durante la llamada. Todo lo demás — el tablero de transacciones, la nota de calidad, el replay — se calcula leyéndolo, nunca se guarda por segunda vez.

Un corte a mitad pierde la llamada, jamás la evidencia
Si el proceso muere — un fallo, un reinicio, un corte — lo ya escrito está escrito: qué se preguntó, qué se autorizó y qué se ejecutó hasta ese instante.

La sesión se re-engancha, no se congela
Si el cliente vuelve a llamar en minutos, el agente retoma el contexto de la conversación anterior. Diseñado sobre el mismo historial; el re-enganche automático es la siguiente fase del roadmap.

La configuración es estado vivo
Un cambio desde la consola — voz, modelo, saludo, número de derivación — aplica a la siguiente llamada, sin desplegar ni reiniciar nada.

LAS CUATRO NEGATIVAS DEL EJECUTOR
sin vale · vale de otra operación · vale caducado · vale ya usado — las cuatro se rechazan en código y quedan como evento en el historial de la llamada.

La prueba de consentimiento de una llamada real, leída de su propio historial: orden 39 preguntó · 46 autorizó · 51 escribió (lámina 7).

Tres capas: la plataforma, el vertical y el negocio

La clave de la reutilización es **qué es código y qué es dato**. La plataforma es una para todos; el vertical es el código de un rubro, reutilizable entre clientes de ese rubro; y el negocio concreto es pura configuración — dar de alta un cliente nuevo no toca una línea de código de la plataforma.

La plataforma CORE · UNA PARA TODOS	Conversación en tiempo real, control de negocio, historial, evaluación, supervisión y consola. No sabe qué es una clínica. no puede importar código de ningún cliente — lo garantiza un test
El vertical BUSINESS · CÓDIGO DEL RUBRO	Los flujos, tools y prompts de un tipo de negocio: «clínicas» sabe qué es una cita y cómo se reserva; «comercio» sabe de pedidos y tickets. Se escribe una vez y sirve a todos los clientes del rubro. sabe qué es una cita — no sabe de Clínica Norte
El negocio TENANT · CONFIGURACIÓN	Cada cliente concreto: nombre, voz, teléfono, saludo, horarios y las credenciales de sus sistemas. Todo cambiabile desde la consola, con efecto en la siguiente llamada. Clínica Norte · Tienda Sur — y el próximo, sin proyecto a medida

En producción hoy Dos verticales con un negocio cada uno, sobre un único despliegue: clínicas (Clínica Norte) y comercio (Tienda Sur). Comparten plataforma; no comparten ni prompts, ni tools, ni datos.
Aislamiento de fallos Un negocio mal configurado queda fuera de ruta y sus llamadas no entran — la flota y los demás clientes siguen operando.
Siguiente fase, dicho honesto Instanciar el segundo negocio de un vertical existente sin copiar código — la separación vertical/negocio ya está trazada; industrializarla es el primer punto del roadmap.

Probado en producción durante esta misma prueba: voz, modelo de IA, saludo y proveedor de voz-a-texto de un negocio cambiados desde la consola — efecto en la llamada siguiente, sin desplegar. La llamada de la lámina 6 corrió con esa configuración.

Los sistemas del cliente se conectan por adapters — y mañana, desde su propio proceso

La regla es una: **el contrato del tool no cambia según dónde viva el código que lo cumple**. Hoy los adapters viven junto al vertical; el diseño ya contempla que vivan en la infraestructura del propio cliente.

Hoy: adapters por negocio

EN PRODUCCIÓN

Un adapter es un módulo pequeño que traduce «crear cita» al sistema real del cliente — su API de agenda, su gestor de pedidos, su ticketing. El vertical define **qué** se hace; el adapter, **contra qué sistema**.

La demo opera con sistemas simulados que exponen **la misma interfaz** que tendría el real: cambiar el simulador por la API verdadera del cliente no toca ni los prompts, ni los tools, ni una prueba.

Las credenciales de cada negocio son suyas, viven en su configuración y jamás se mezclan entre clientes.

Con un contact center existente, la plataforma entra como un destino SIP más de su ACD: recibe la llamada de la cola, y la transferencia la devuelve a un agente humano de esa misma cola. El estado del agente y el CTI se integran por adapter, como cualquier otro sistema del cliente.

El catálogo de tools viaja con sus contratos: el mismo control gobierna un tool local y uno remoto, y el historial no distingue dónde corrió el código — solo qué se autorizó y qué se ejecutó.

Mañana: el agente del cliente vive en su proyecto

DISEÑO TRAZADO — SIGUIENTE FASE

«**Su agente vive en su proyecto; nuestra plataforma le da vida a todos.**» El proceso del cliente mantiene sus tools y sus prompts, y se conecta **saliente** por WebSocket — nadie abre puertos entrantes, no hay webhooks que firmar.

hello → register { catálogo de tools + contratos } → invoke / result / fail → ping

LO QUE NO SE MUDA CON EL CÓDIGO

La autorización, el consentimiento, el historial y la máscara de datos personales quedan en la plataforma. Un tool remoto pasa por el mismo control que uno local — **la autoridad no viaja**.

EL ENCHUFE YA EXISTE

El ejecutor de tools es un contrato con una sola implementación (local) hoy — la segunda implementación (remota) entra sin tocar al resto del sistema.

La operación diaria: todo lo que un responsable mira, en una consola

La auditoría de cada llamada ya quedó demostrada (láminas 6 y 7) y la evaluación continua también (lámina 3). Esta es la vista de **flota**: lo que la operación consulta cada mañana, calculado siempre desde el mismo historial.

El tablero del negocio

Las transacciones reales, no las conversaciones: citas creadas, movidas y canceladas; pedidos y tickets con sus estados — cada fila enlaza a la llamada que la produjo.

`consola` → `Board`, por negocio y por día

El registro de llamadas

Cada sesión con su resultado, coste, nota de calidad, turnos y duración — y dentro, la grabación, la transcripción y el historial completo.

`consola` → `Sessions`

Las llamadas en vivo

Qué está sonando ahora mismo, con la puerta de supervisión al lado: escuchar, susurrar, tomar la línea.

`consola` → `Supervisor`

La calidad, corrida a corrida

Cada batería de evaluación con su score por métrica y la diferencia contra la corrida anterior — y el botón para lanzar otra, acotada y con registro.

`consola` → `Evals`, con los datasets a la vista

El replay como QA

Cualquier llamada almacenada se reevalúa bajo demanda con las mismas métricas — la evidencia basta, no hace falta el audio.

`también por línea de comandos`, para el equipo técnico

La noche vigila sola

Cada madrugada, un cliente sintético llama a la plataforma desplegada con presupuesto acotado; un rojo se ve como rojo, con el transcript adjunto.

`programado a las 04:00`, resultado en la consola

0,0162 €

UNA LLAMADA REAL COMPLETA

Billing preparado desde el primer día: cada llamada cierra con su coste en euros por proveedor y por modelo, escrito en su propio historial al tipo del día — la factura por cliente es una suma sobre datos ya auditados, no una estimación. Tarifas por cliente, topes de consumo y alertas son un umbral sobre estos mismos datos — primera fase del roadmap.

Todas las vistas se calculan del historial append-only – no existe una segunda base de datos que pueda discrepar de la evidencia.

Cada permiso es una concesión firmada que dice exactamente qué alcanza

Nada opera por convención: todo lo que entra, escucha, escribe o interviene lo hace con un permiso explícito, acotado y con caducidad.

Identidad y autoridad firmadas

Cada participante — cliente, agente, supervisor, evaluador — entra con un permiso firmado que enumera sus poderes exactos y caduca solo. La identidad la certifica el servidor de medios: **nada escrito en un mensaje puede fingir autoridad**.

Segregación total por cliente

Un negocio no puede ver, nombrar ni rozar los datos de otro — y la evaluación lo vigila como métrica en cada llamada (lámina 3: privacidad, ninguna fuga). Sus credenciales viven en su configuración, nunca en código ni en repositorio.

Telefonía con superficie mínima

Cuatro capas antes de aceptar una llamada: la red solo admite los rangos publicados del operador (denegación explícita — el resto del mundo nunca llega al servidor); el puente descarta sin respuesta cualquier intento que no presente la troncal correcta — un escáner no aprende nada; la troncal verifica número y origen por segunda vez; y solo entonces el número marcado resuelve a un negocio.

Las grabaciones, tras una puerta

El audio de una llamada nunca está en un directorio público ni en el repositorio: se sirve solo por una ruta autenticada que valida la sesión — y cada proyecto puede optar por no grabar.

DATOS PERSONALES ENMASCARADOS POR VALOR – NO SOLO POR NOMBRE DE CAMPO	
LO QUE RECIBE EL SISTEMA DEL CLIENTE «Clínica Norte: Ana García Ruiz, su cita queda el martes 1/9 a las 09:00»	LO QUE QUEDA EN EL HISTORIAL «Clínica Norte: An*****, su cita queda el martes 1/9 a las 09:00»

MARCO REGULATORIO – AI ACT (UE 2024/1689) Y RGPD

La atención al cliente conversacional es **riesgo limitado**: sin evaluación de conformidad, con obligación de transparencia (art. 50) — el agente se presenta como IA en el saludo, configurable por negocio, y la voz sintética es marcabable como generada. Ninguna práctica prohibida: sin biometría, sin reconocimiento de emociones, sin scoring. La supervisión humana (lámina 9) y el historial inmutable exceden lo exigido para esta categoría; la máscara por valor, la retención declarada y el acceso autenticado a grabaciones cubren el RGPD.

El enmascarado aprende los valores del propio resultado – un nombre que ninguna orden mencionó queda cubierto igual, hasta dentro de un SMS. Verificado por test.

LiveKit resuelve el tiempo real; nosotros, la garantía transaccional encima

EL STACK, CON NOMBRES

LiveKit autoalojado resuelve la capa de tiempo real completa: servidor de medios WebRTC, puente telefónico SIP, un proceso aislado por llamada y los permisos firmados por identidad. Sin él, nada de esto existiría en el plazo de una prueba.

Encima construimos lo que LiveKit no da — y esa es la tesis del documento: el control transaccional con consentimiento, el historial inmutable, la máscara por valor, los cuatro niveles de evaluación y la consola de operación.

Proveedores por contrato: Soniox / Deepgram (voz a texto), ElevenLabs (texto a voz), Claude / GPT (modelo). Runtime Python, base embebida — y su paso a Postgres tiene el disparador escrito: el día que un segundo proceso escriba.

DESPLIEGUE Y OPERACIÓN

Desplegar es un comando idempotente; la configuración de los negocios es estado vivo y no viaja con el deploy. El rollback es redeclarar la versión anterior.

El gate de calidad es la evaluación: la batería conversacional en integración continua, y la nocturna vigilando lo desplegado. Sin GPU en todo el sistema.

Concurrencia probada contra este nodo (llamadas reales simultáneas): con 1 y con 4 a la vez — el tamaño del pool precalentado — completa el 100%, con la respuesta en 3,8 s de mediana bajo carga (2,25 s en solitario); con 8, dos de ocho esperan proceso. El techo está medido, no estimado.

Escalar tiene disparadores, no adjetivos: concurrencia sobre el techo medido → segundo nodo de workers (sin estado, el dispatch ya reparte) · segundo escritor → Postgres · otra región → servidor de medios federado.

ROADMAP POR FASES

FASE 1 – LA TESIS, INDUSTRIALIZADA
«Los verticales son código; los negocios, configuración»
El segundo negocio de un rubro se da de alta sin copiar una línea : el código de «clínicas» sirve a todas las clínicas; cada una trae su voz, su número, sus credenciales y sus horarios.
2 · Tools remotos — el protocolo de la lámina 12: el código del cliente corre en su infraestructura, la autoridad se queda aquí.
3 · Re-enganche automático — la llamada que se corta retoma contexto al volver a llamar.
4 · Escala multi-nodo — según los disparadores de la izquierda, no antes.

TRADE-OFFS PRINCIPALES – DECIDIDOS CON MEDICIÓN

LiveKit autoalojado, evaluado frente a Vapi y Pipecat — Vapi es un panel sobre el bucle de otro: el prompt, el estado y las credenciales viven en su SaaS, y la tesis de este documento — control, consentimiento y auditoría en el backend — sería inexpresable allí. Pipecat da el pipeline, no el SFU ni el SIP ni la supervisión. LiveKit deja el bucle, los datos y la telefonía en casa; la dependencia se asume con la migración como coste conocido.

Motor conversacional propio — un motor SaaS dejaría la autorización y la auditoría fuera del bucle; el control transaccional exige poseerlo.

Sub-agentes especializados antes que un agente que lo hace todo — medido aquí: una herramienta extra en una etapa cuesta ~17 puntos de acierto (38/40 sin ella, 16/20 con ella, 154 corridas). Cada mostrador es un agente de dos o tres verbos y el traspaso lleva el contexto: la precisión se compra quitando opciones, no añadiendo prompt.

Generación anticipada apagada — medida: con fin de turno en ~0,4 s, especular no ocultaba latencia y solo gastaba modelo.

Base embebida antes que Postgres — single-node deliberado — el contrato de persistencia no depende del storage local (todo proceso escribe por el plano de control, nunca contra el fichero). Un único escritor hoy; el segundo es el disparador, y ese día migrar es un cambio de conexión, no de arquitectura.

Coste de infraestructura conocido y coste por llamada medido en céntimos — la decisión de escalar siempre tendrá un número delante. Plataforma en vivo: <https://lk.bernardocastro.dev>